Predicting Term Deposit Subscription

Bank Marketing: un approccio di classificazione supervisionata

Davide De Santis

Progetto di Machine Learning A.A. 2025–2026

Obiettivo: identificare i clienti prioritari

Scenario operativo

Prima che il prossimo contatto telefonico venga programmato o effettuato, assegnare a ogni cliente uno score di propensione alla sottoscrizione di un deposito a termine.

- Problema di **classificazione binaria**: $Y \in \{0, 1\}$.
- Quantità teorica: $P(Y = 1 \mid X = x)$.
- Output del modello: $\hat{p}(x)$, utilizzato per **ranking** e classificazione.

Regola decisionale

$$\hat{y} = \begin{cases} 1 & \hat{p}(x) \geq \tau \\ 0 & \hat{p}(x) < \tau \end{cases}$$

La soglia τ sarà scelta *dopo* il confronto dei modelli.

Dataset: UCI Bank Marketing

Osservazioni	**45.211**
Predittori originali	**16**
Target	**1**
Task	**Binario**

- Variabili numeriche e categoriche.
- Nessun valore NaN rilevato.
- La categoria `unknown` è mantenuta come modalità valida.

Gruppi di variabili

Profilo	`age`, `job`, `education`, `balance`, `housing`, `loan`, ...
Contatti	`campaign`, `day`, `month`, `contact`, `duration`
Storico	`pdays`, `previous`, `poutcome`

Fonte: UCI Bank Marketing, file `bank-full.csv` (recuperato dal mirror Kaggle indicato nel notebook).

Prediction setting e disponibilità delle informazioni

Feature escluse dal modello principale

`contact`	Canale del contatto
`day`, `month`	Data del contatto
`duration`	Durata della chiamata

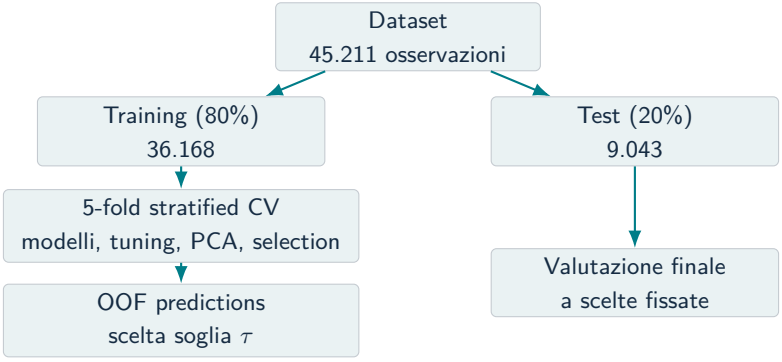
Nello scenario scelto queste variabili non vengono considerate disponibili al momento della previsione.

Scelta centrale del progetto

Una feature molto predittiva non è necessariamente **utilizzabile al prediction time**.

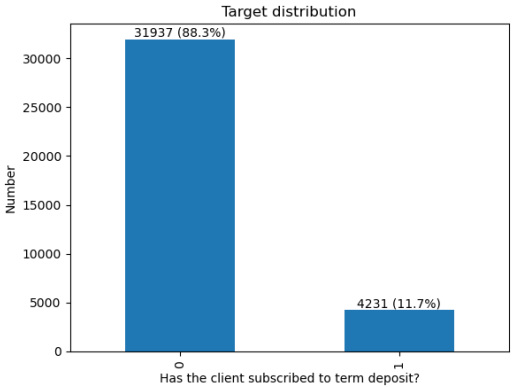
L'esclusione è un'**assunzione operativa** del progetto, non una proprietà universale del dataset.

Protocollo sperimentale: separare selezione e valutazione



Split stratificato sul target, `random_state=42`; preprocessing rifittato dentro ogni fold.

Class imbalance: perché non ottimizzare l'Accuracy?



11,7%

classe positiva

88,3%

accuracy del classificatore sempre negativo

Una buona Accuracy non implica il riconoscimento dei clienti che sottoscrivono.

Metrica primaria: Average Precision

Average Precision (AP) sintetizza la curva Precision–Recall al variare della soglia:

$$\mathrm{AP} = \sum_{k} (R_k - R_{k-1}) P_k$$

- Valuta la qualità del **ranking degli esempi positivi**.
- Evita di fissare subito un threshold.
- È più informativa dell'Accuracy per l'obiettivo del progetto.

Punto di riferimento

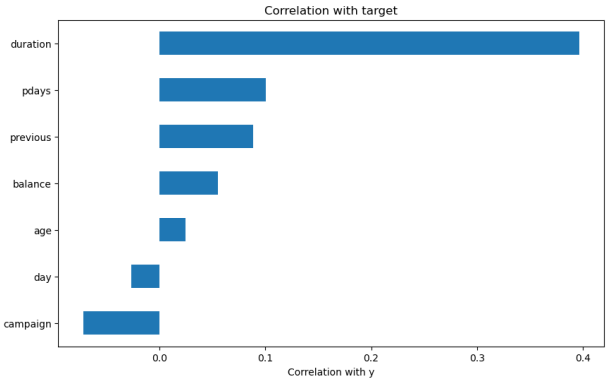
AP $\approx$ 0,117

Ranking non informativo, con prevalenza positiva $\approx 11,7\%$.

Precision, Recall, F1 e ROC-AUC rimangono metriche complementari.

Exploratory Data Analysis

EDA: associazioni marginali con il target

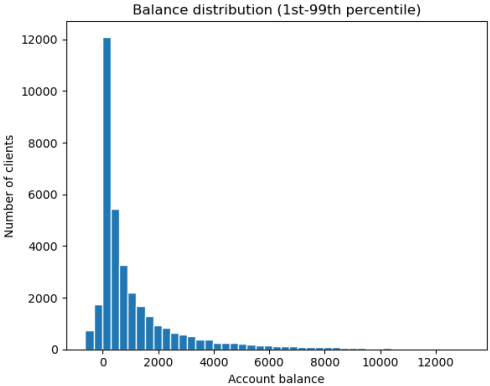


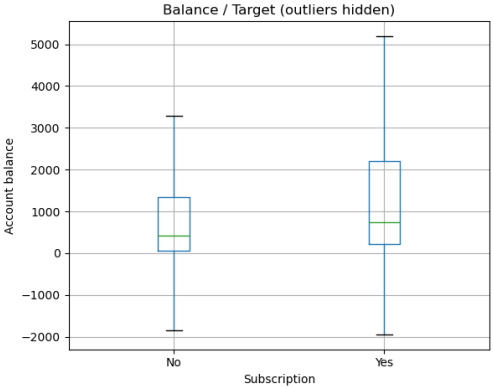
Osservazioni

- `duration`: associazione numerica più marcata.
- `pdays`, `previous`, `balance`: correlazione positiva.
- `campaign`: correlazione negativa.

Analisi **esplorativa** sul solo training: correlazione $\neq$ causalità.

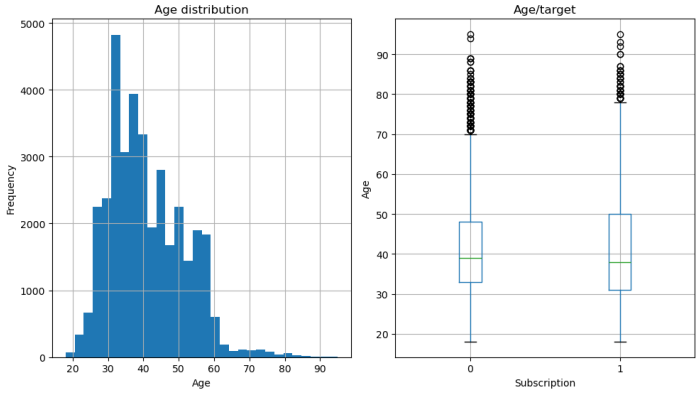
EDA: distribuzione di `balance`





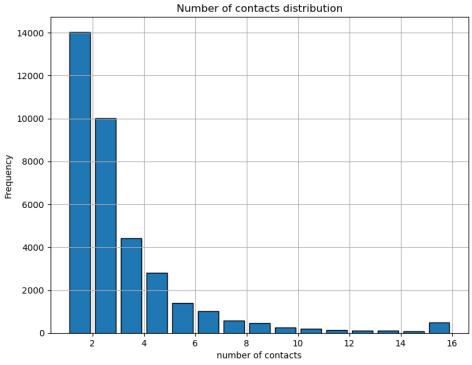
Mediana ≈ 740 euro per $Y = 1$ e ≈ 419 euro per $Y = 0$; distribuzione fortemente asimmetrica. Il taglio dei percentili è usato solo per la visualizzazione.

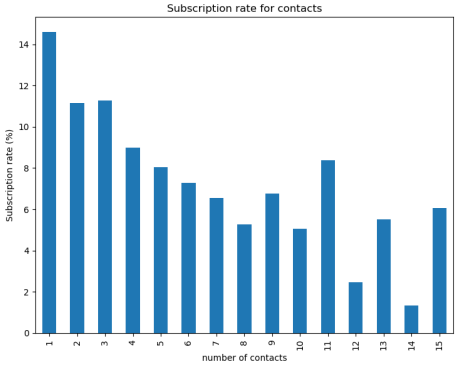
EDA: distribuzione di age



Età media $\approx 41,6$ anni per $Y = 1$ e $\approx 40,8$ per $Y = 0$: le distribuzioni si sovrappongono ampiamente. La feature, considerata da sola, ha potere discriminativo limitato.

EDA: contatti durante la campagna





`campaign` è asimmetrica: più contatti osservati si associano generalmente a un minor tasso di sottoscrizione.

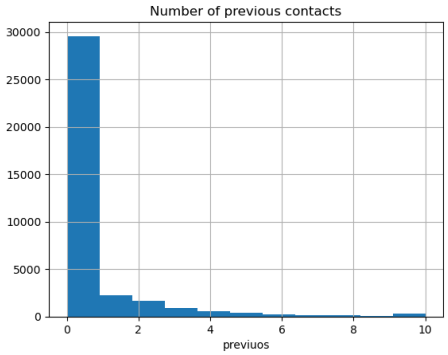
Associazione descrittiva, non interpretata causalmente; support più piccolo per conteggi elevati.

EDA: storia dei contatti precedenti

Il valore speciale di `pdays`

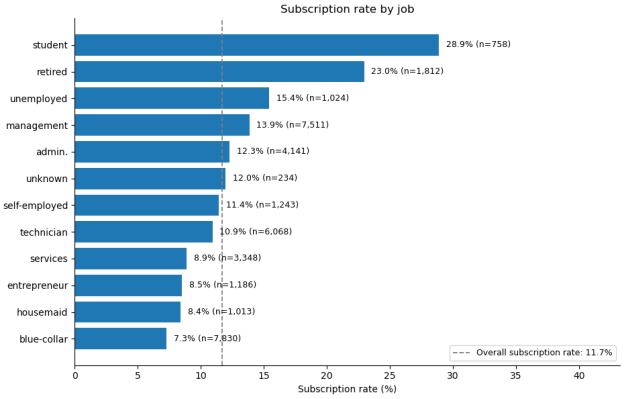
Storia precedente	Tasso $Y = 1$
Mai contattato (-1)	**9,2%**
Già contattato	**22,8%**

Interpretazione: l'assenza di storia non è semplicemente una distanza temporale.



`previous`: distribuzione concentrata in zero.

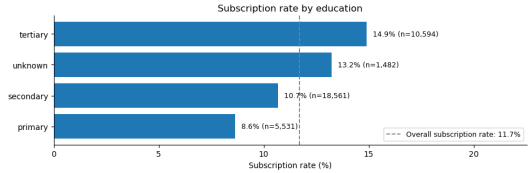
EDA: profilo del cliente – `job`



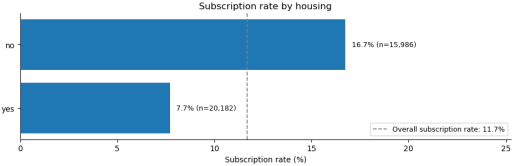
Studenti e pensionati hanno tassi di sottoscrizione relativamente elevati; per ogni categoria va considerato anche il support.

EDA: istruzione e mutuo immobiliare

`education`



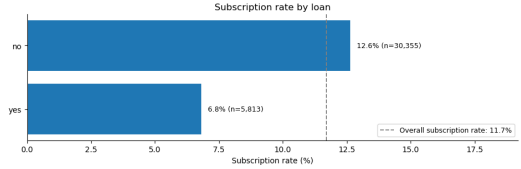
`housing`



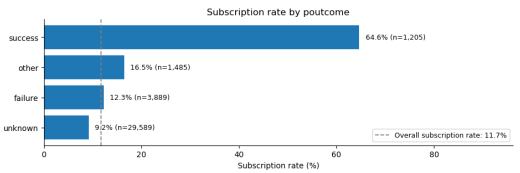
I tassi variano con le caratteristiche socio-economiche, ma nessuna feature marginale risolve da sola il problema.

EDA: prestito personale e campagna precedente

`loan`

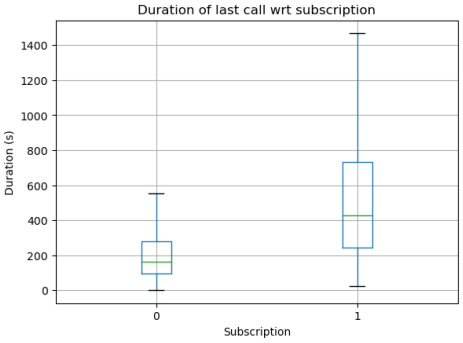


`poutcome`



`poutcome=success` è fortemente associata alla sottoscrizione nella campagna osservata.

EDA: feature informative ma non utilizzabili



Durata della chiamata distinta per classe.

- La `duration` risulta particolarmente associata al target.
- È nota **solo dopo il contatto**.
- La sua inclusione viene valutata *separatamente* come esperimento diagnostico.

Modelli e validazione

Feature engineering: una rappresentazione coerente

1. **Eliminazione delle feature assunte non disponibili**: `contact`, `day`, `month`, `duration`.
2. **Storia dei contatti**: codifica esplicita del valore speciale

$$\text{prev_cont} = \mathbb{1}_{\{\text{pdays} \neq -1\}}.$$

3. **Numero di contatti precedenti nella campagna**:

$$\text{log_campaign} = \log(1 + \text{campaign} - 1) = \log(\text{campaign}).$$

La ricostruzione di `campaign-1` si basa sul prediction setting adottato.

Preprocessing senza leakage tra fold

Numeriche

`StandardScaler`

Categoriche

`OneHotEncoder(handle_unknown="ignore")`

Integrazione

`ColumnTransformer`

`Pipeline`

`StratifiedKFold(5)`

35 colonne trasformate (numeriche + indicatori one-hot).

Scaling, encoding e successivamente eventuale selezione/PCA vengono appresi solo sul training fold.

Modelli: confronto tra ipotesi induttive

Modello	Caratteristica	Motivazione nel progetto
Logistic Regression	Modello lineare probabilistico	Riferimento semplice e interpretabile
Linear SVC	Modello lineare basato sul margine	Confronto con diversa funzione obiettivo
Decision Tree	Split gerarchici non lineari	Interazioni e strutture non lineari
Random Forest	Ensemble di alberi	Verificare i benefici dell'aggregazione e del tuning
DummyClassifier	Classe maggioritaria	Baseline non predittiva

Si confrontano approcci lineari, non lineari ed ensemble.

Primo confronto: 5-fold stratified CV

Modello	AP media	Dev. std.
Dummy baseline	0,1170	0,0001
Logistic Regression	**0,3550**	0,0106
Logistic Regression balanced	0,3525	0,0102
Decision Tree	0,3114	0,0223
Random Forest	0,3219	0,0153
Linear SVC	0,3511	0,0099

Le tre famiglie più promettenti per AP: Logistic Regression, Linear SVC e Random Forest.

Imbalance: effetto di `class_weight=balanced`

Metrica	Logistic	Balanced
Precision	0,666	0,229
Recall	0,162	0,597
F1	0,261	0,331
AP	0,355	0,353

Osservazione

La pesatura modifica molto il **punto operativo**, ma non migliora l'AP.

La metrica di ranking e le metriche ottenute con una soglia fissata descrivono aspetti differenti.

Hyperparameter tuning: impostazione

Logistic Regression / Linear SVC

- $C \in \{0.01, 0.1, 1, 10, 100\}$
- `class_weight` $\in \{$`None`, `balanced`$\}$

Strumento: `GridSearchCV`
Metrica: Average Precision

Random Forest

- `n_estimators` $\in \{100, 300\}$
- `max_depth` $\in \{\text{None}, 5, 10\}$
- `min_samples_leaf` $\in \{1, 5, 10\}$
- `class_weight` $\in \{$`None`, `balanced`$\}$

Ogni configurazione include nuovamente il preprocessing nella CV.

Hyperparameter tuning: i modelli selezionati

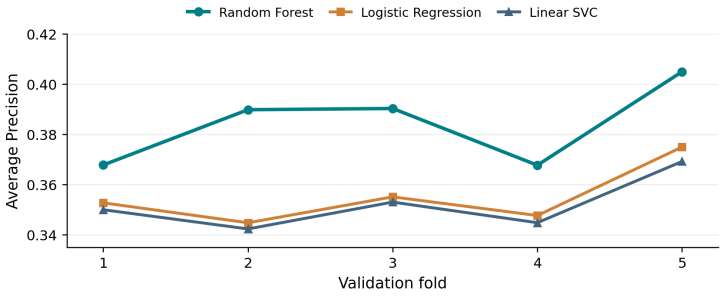
Modello	CV AP	Dev. std.
Logistic Regression ($C = 1$)	0,3550	0,0106
Linear SVC ($C = 0.01$)	0,3518	0,0094
Random Forest	**0,3841**	0,0144

Random Forest: migliore configurazione

`n_estimators=300` | `max_depth=10`
`min_samples_leaf=10` | `class_weight=None`

La Random Forest ottimizzata supera la Logistic Regression di circa 0,029 punti di AP.

Stabilità del confronto nei cinque fold



Osservazione

La Random Forest ottimizzata ottiene AP più elevata sia della Logistic Regression sia della SVC in tutti i cinque validation fold.

Overfitting: prima e dopo il tuning

Random Forest	Train AP	Val. AP	Gap
Iniziale	0,9999	0,3219	0,6780
Ottimizzata	0,4479	**0,3841**	**0,0638**

Iniziale: quasi perfetta sui training fold ma molto peggiore sui validation fold.

Ottimizzata: alberi meno complessi, minore gap, maggiore validation AP.

Evidenza forte di overfitting iniziale e riduzione del gap dopo il tuning.

Riduzione della dimensionalità

Feature selection: Logistic Regression e penalità L^1

Metodo

`SelectFromModel` con Logistic Regression penalizzata L^1.

	Dimensione	**CV AP**
Senza selection	35	0,3550
Con selection	**27**	0,3545

Risultato

Riduzione di circa **23%** delle colonne trasformate con perdita di AP trascurabile.

La selezione è inclusa nella pipeline e ripetuta entro ogni fold.

Feature selection: Random Forest

Soglia	Feature	CV AP
Nessuna selection	35	**0,3841**
Mediana	**18**	0,3826
Media	10	0,3762
1.25× media	9	0,3718

- La soglia mediana riduce le colonne di circa **49%**.
- La perdita media di AP è circa **0,0015**.
- Il modello completo mantiene la migliore AP e solo 35 feature trasformate.

Decisione finale: non applicare feature selection alla Random Forest.

Feature extraction: PCA e scaling

Esperimento con Logistic Regression

1. **Scaling originale**: numeriche standardizzate, categoriche one-hot.
2. **Scaling globale**: standardizzazione di tutte le colonne dopo il one-hot encoding.

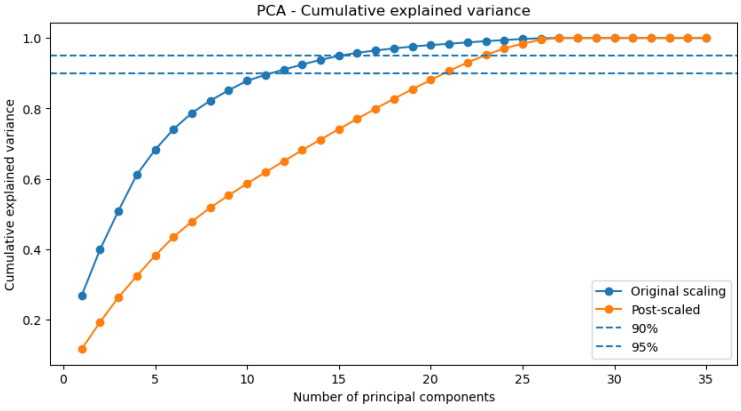
Cautela metodologica

PCA massimizza la varianza spiegata di X, **non** direttamente l'informazione su Y.

La standardizzazione delle dummy può amplificare categorie rare: non è una scelta universalmente migliore.

$$z_k = w_k^\top x \qquad \text{(nuove componenti lineari)}$$

PCA: varianza spiegata e numero di componenti



Per la stessa frazione di varianza, il numero di componenti dipende sensibilmente dallo scaling.

PCA: confronto quantitativo delle prestazioni

Scaling	PCA	Componenti	CV AP
Originale	No	35	0,3550
Originale	90%	12	0,2839
Originale	95%	16	0,2849
Globale	No	35	0,3548
Globale	90%	**21**	**0,3557**
Globale	95%	23	0,3556

- PCA 90% dopo scaling globale: **35** $\rightarrow$ **21** componenti, AP comparabile.
- Nessun miglioramento predittivo sostanziale; interpretabilità ridotta.

Decisione finale: mantenere la rappresentazione originale.

Dimensioni misurate sul fit dell'intero training; durante la CV il numero può variare tra fold.

Esperimento diagnostico: reintrodurre `duration`

Logistic Regression	CV AP
Senza `duration`	0,3550
Con `duration`	**0,5199**

$+0,165$ **AP**

Interpretazione

La feature è estremamente informativa, ma **non disponibile prima del contatto**.

Esperimento separato; non modifica il prediction setting del modello finale.

Decisione e valutazione

Threshold tuning: dagli score alla classe

Modello selezionato: tuned Random Forest, secondo la CV AP.

- Generazione di score **out-of-fold** sul training.
- Valutazione di soglie candidate ricavate dagli score.
- Selezione della soglia che massimizza F_1.

$$\tau^* = \arg\max_{\tau} F_1(\tau)$$

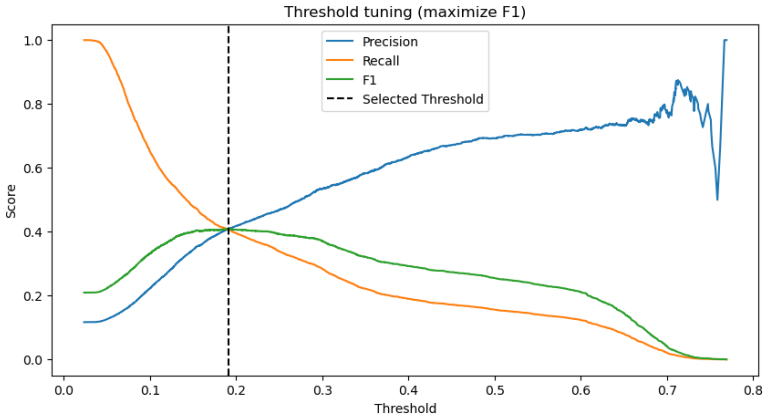
F1 è un compromesso convenzionale, poiché non è disponibile una matrice di costi e benefici.

Risultato OOF

$$\tau^* = 0,1913$$

Precision	0,4103
Recall	0,4077
F1	0,4090

Threshold tuning: Precision, Recall e F1



La soglia selezionata ($\approx 0,191$) è inferiore a quella di default (0,5).

Valutazione finale: tuned Random Forest sul test

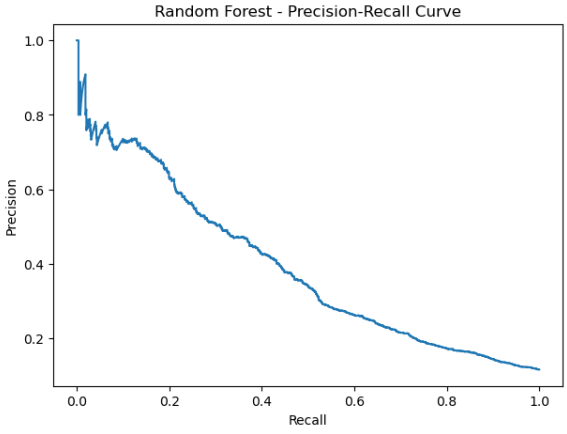
Metriche sul test	
Accuracy	0,8644
Precision	0,4200
Recall	0,4168
F1	0,4184
ROC-AUC	0,7497
Average Precision	**0,3909**

Confronto AP

CV sul train	0,3841
Test finale	**0,3909**

L'AP sul test è vicina a quella stimata in CV: non emerge un peggioramento evidente del ranking sul campione di test.

Curva Precision–Recall sul test



AP sul test

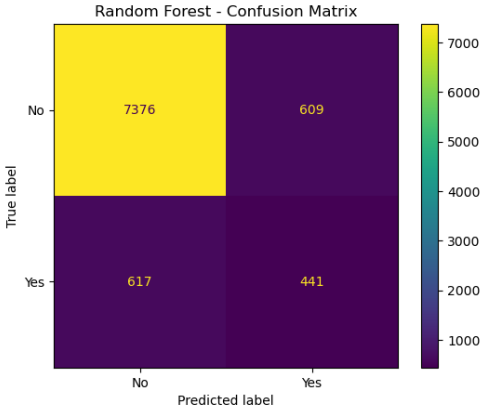
0,3909

Prevalenza positiva

0,1170

Il ranking concentra i veri positivi più di una scelta casuale.

Confusion matrix e compromesso operativo



True Positive	**441**
False Positive	609
False Negative	617
True Negative	7.376

La soglia selezionata recupera parte dei positivi, accettando falsi positivi. L'Accuracy può essere inferiore a quella della baseline sempre negativa.

Interpretazione operativa: prioritizzazione

Clienti nel test	9.043
Clienti classificati positivi	**1.050**
Sottoscrittori tra i classificati positivi	**441**
Precision del gruppo selezionato	**42,0%**
Prevalenza generale	11,7%

Concentrazione dei positivi $\approx 3,6\times$ la prevalenza generale

Attenzione

Questo risultato illustra l'utilità del **ranking**; non costituisce una misura di profitto senza costi, ricavi e budget della campagna.

Error Analysis

Error analysis: storico dei contatti

prev_cont	Support	Positivi reali	Recall	FNR
0	7.370	657	18,57%	81,43%
1	1.673	401	79,55%	20,45%

- Il Recall cresce da **18,57%** a **79,55%** nei clienti già contattati in campagne precedenti.
- In assenza di uno storico informativo il modello tende a non riconoscere molti clienti che poi sottoscrivono.

Analisi descrittiva sul test, non usata per modificare il modello.

Error analysis: poutcome

Esito precedente	Support	Positivi reali	Recall	FNR	FPR
unknown	7.370	657	18,57%	81,43%	3,46%
failure	1.012	140	56,43%	43,57%	22,13%
other	355	62	66,13%	33,87%	26,28%
success	306	199	100%	0%	100%

- Nel test, poutcome=unknown identifica lo stesso gruppo di prev_cont=0: non sono due evidenze indipendenti.
- Con poutcome=success, tutti i 306 clienti del gruppo vengono classificati positivi alla soglia fissata, inclusi i 107 negativi reali.

Risultati specifici del campione di test; non rappresentano regole universali.

Error analysis: `housing` e `loan`

Sottogruppo	Recall	FNR
`housing=yes`	16,62%	83,38%
`housing=no`	55,67%	44,33%
`loan=yes`	13,64%	86,36%
`loan=no`	44,23%	55,77%

I gruppi associati a tassi di sottoscrizione inferiori nell'EDA presentano anche più I positivi non riconosciuti.

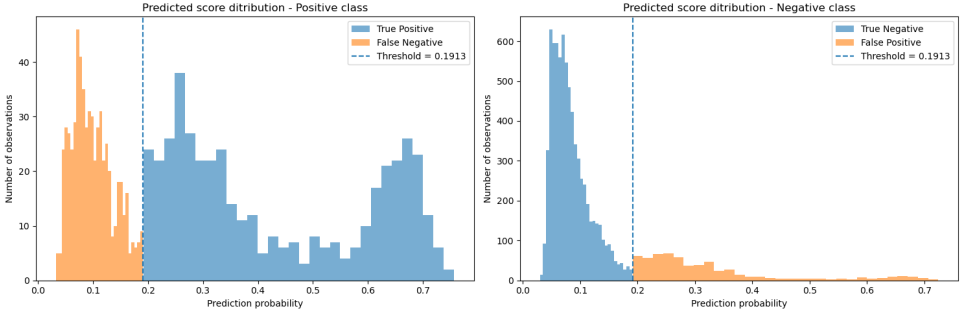
tassi sono condizionati al gruppo; non implicano relazioni causali.

Error analysis: differenze tra categorie professionali

Job	Positivi nel gruppo	Recall	FPR
Student	50	84,00%	61,54%
Retired	100	78,00%	34,38%
Blue-collar	137	24,09%	1,87%
Entrepreneur	22	9,09%	2,15%

- Alcuni gruppi ricevono frequentemente predizioni positive: Recall elevato *e* FPR elevato.
- Interpretare con prudenza le categorie con pochi esempi positivi (es. `entrepreneur`).

Error analysis: distribuzione degli score



False positive: score alti senza sottoscrizione. False negative: positivi reali con score sotto la soglia.

Confident errors: due pattern ricorrenti

False positive con score più alti

- `poutcome=success`
- `prev_cont=1`
- Frequentemente `housing=no`, `loan=no`

False negative con score più bassi

- Frequentemente `poutcome=unknown`
- `prev_cont=0`
- Spesso `housing=yes` e `blue-collar`

L'assenza di una storia precedente informativa è associata a maggiori difficoltà nel riconoscere i positivi.

Conclusioni

Limitations: validità del contesto e delle informazioni

- **Dati storici**: uno split casuale stratificato non sostituisce una validazione su campagne temporalmente successive.
- **Prediction setting**: la disponibilità di `contact`, `day`, `month`, `duration` dipende dallo scenario operativo.
- **Storico aggregato**: `pdays`, `previous`, `poutcome` non costituiscono una cronologia completa delle interazioni.
- **Associazioni, non causalità**: EDA ed error analysis non misurano effetti causali.

Limitations: soglia e utilizzo operativo

Soglia scelta sul training

La soglia $\tau^* \approx 0,1913$ massimizza l'F1 sulle predizioni out-of-fold. Senza informazioni sui costi e sui benefici, non possiamo considerarla **economicamente ottimale**.

Prima di un'applicazione reale servirebbero:

- una validazione su campagne temporalmente successive;
- una stima del costo dei contatti e del beneficio delle sottoscrizioni;
- la definizione di un budget e di una soglia decisionale coerente con gli obiettivi della campagna.

Conclusioni principali

1. Il **prediction setting** guida la scelta delle variabili: `duration` è predittiva ma esclusa.
2. La **Random Forest ottimizzata** è il miglior modello per AP fra quelli confrontati (CV $0,3841$; test $0,3909$).
3. La **regolarizzazione degli alberi** riduce marcatamente l'overfitting iniziale.
4. **Feature selection e PCA** comprimono i dati, ma non migliorano sostanzialmente l'AP.
5. L'**error analysis** rivela una forte dipendenza dalle informazioni sui contatti precedenti.

Il modello è promettente per prioritizzare i clienti, previa validazione operativa e temporale.

Grazie per l'attenzione

Appendice: metriche e threshold

Metrica	Interpretazione
Precision	$TP/(TP + FP)$
Recall	$TP/(TP + FN)$
F1	$2 \cdot \text{Precision} \cdot \text{Recall}/(\text{Precision} + \text{Recall})$
FPR	$FP/(FP + TN)$
FNR	$FN/(TP + FN)$

La baseline sempre negativa ha accuracy $\approx 88,3\%$, ma Recall e F1 della classe positiva pari a zero.

Appendice: condizioni per la feature selection

- Le 35 *feature* si riferiscono alle **colonne dopo lo scaling/one-hot encoding**, non alle 16 variabili originali.
- Le feature riportate come selezionate sono ottenute dal fit del selettore sull'intero training set.
- Nella CV, `SelectFromModel` e PCA sono **rifittati dentro ogni fold**: le feature e il numero di componenti possono cambiare.
- Ridurre la dimensionalità non garantisce un miglioramento predittivo.